관측 행동 페르소나와 가정 기반 Uplift를 결합한 전자상거래 쿠폰 정책 시뮬레이터

익명 저자 KSC 투고 초안

초록

전자상거래의 쿠폰 정책은 즉시 구매뿐 아니라 재방문, 반복 노출 및 이탈 상태를 변화시키므로 단일 시점 구매예측만으로 평가하기 어렵다. 실제 서비스의 장기 온라인 탐색은 쿠폰비용과 사용자 피로를 유발하며, 공개 로그에서는 동일 사용자의 처치 및 비처치 잠재결과를 동시에 관측할 수 없다. 이에 본 연구는 관측 행동과 비식별 개입가정을 분리한 정책 실험용 사용자 시뮬레이터를 제안한다. REES46 Cosmetics Shop 로그에서 masked bidirectional-GRU로 48차원 사용자 표현을 학습하고, 행동 빈도와 세션 내 전이를 이용해 페르소나와 lifecycle을 구성하였다. 2차 상태특징을 사용하는 maximum-entropy 선택모형과 이산 세션 간격 모형을 결합한 무쿠폰 생성기의 행동비율 RMSE는 0.0540이었다. Tianchi O2O의 비무작위 쿠폰 수령 차이는 인과효과 대신 합성환경의 보정 모멘트로 사용하였다. 독립 합성 표본의 가중 14일 구매율 차이는 목표 12.62%p와 생성 12.55%p로 대응하였다. 주 1회 쿠폰 환경에서 1,000명, 13주 학습 후 별도 5,000명, 52주를 평가한 결과 discrete SAC는 사용자당 20.90회의 쿠폰으로 순이익 30,893.46을 기록하였다. 결과는 단일 seed와 가정 기반 uplift에 조건부이며 실제 인과효과의 증거로 해석하지 않는다. **주제어:** 사용자 시뮬레이션, 행동 페르소나, Maximum Entropy IRL, Uplift Modeling, Contextual Bandit, 강화학습

1 서론

쿠폰 정책은 현재 구매와 이후 재방문을 함께 바꾸므로 정책의 장기 가치를 평가해야 한다. 그러나 실제 사용자에게 여러 정책을 반복 탐색하면 직접 비용과 피로가 발생한다. 행동 로그는 순차적 탐색과 구매를 제공하지만 처치 반사실을 제공하지 않고, 쿠폰 로그의 수령과 타기팅이 비무작위이면 집단 차이는 선택편향을 포함한다. 따라서 관측된 사용자 이질성과 시간적 행동을 보존하면서 개입효과를 명시적인 가정으로 통제할 수 있는 재현 가능한 시뮬레이터가 필요하다.

본 연구는 다음 네 단계로 구성된다. 첫째, 행동과 세션 경계 토큰을 마스킹하고 복원하는 양방향 GRU로 사용자 표현을 학습한다. 둘째, 행동 빈도와 전이가 다른 페르소나를 정의하고 maximum-entropy 선택모형과 세션 간격 모형으로 무처치 행동을 생성한다. 셋째, Tianchi의 관측 차이를 합성 canonical type과 쿠폰 감쇠항의 보정 모멘트로 사용한다. 넷째, 동일한 합성 사용자 난수 아래 bandit과 deep RL의 학습비용 및 장기 순이익을 비교한다.

순차 추천은 다음 행동이나 아이템 예측에 초점을 두며 [3], 전통적 uplift modeling은 처치의 증분 반응을 주로 단일 결과에서 추정한다 [6]. RecSim [7]과 RecoGym [8]은 순차 추천 정책을 위한 구성 가능한 환경을 제공하고, Virtual-Taobao [9]는 대규모 독점 로그와 온라인 검증으로 가상환경을 구축하였다. 본 연구는 공개 데이터에서 행동 생성과 쿠폰 반응을 서로 다른 증거 수준의 모듈로 분리하고, 쿠폰 모듈을 제거하면 관측 기반 무처치 생성기로 정확히 환원되도록 설계한다.

2 데이터

주 행동 데이터는 REES46 Cosmetics Shop의 2019년 10월부터 2020년 2월까지 5개 CSV, 총 20,692,840행이다 [1]. `user_id mod 100=0`인 고정 약 1% 표본 216,093행에서 최대 12,000명의 사용자 시퀀스를 구성하였다. 이벤트는 `view`, `cart`, `remove_from_cart`, `purchase`이며 명시적인 세션 ID를 제공한다. Electronics는 제거 행동이 없어 보조 분석에만 사용하였다.

쿠폰 반응 참고 자료는 Tianchi O2O 로그다 [2]. 2016년 5월 15일을 기준일로 두고, 기준일 수령 기록과 이후 14일 구매 기록을 비교하였다. 대리군은 기준일 이전 14일의 클릭과 구매만으로 정의하였다. 다섯 기준일의 placebo 구매율 차이가 6.85-8.87%p이고 수령군의 후속 쿠폰 수령률도 12.11-31.31%p 높아, 관측 차이를 인과적 CATE로 사용하지 않았다.

3 제안 방법

3.1 Masked bidirectional-GRU 표현

각 사용자의 행동 사이에 세션 경계 토큰을 삽입하고 앞 64개 토큰을 유지한다. 전체 유효 위치의 15%를 마스킹하고 원래 토큰을 복원하도록 학습한다. 목적함수는

$$\mathcal{L}_{\text{mask}} = -\sum_{i \in \mathcal{M}} \log p_\psi(x_i \mid x_{\setminus \mathcal{M}}) \tag{1}$$

이다. 토큰 임베딩은 16차원, 양방향 GRU의 방향별 hidden size는 24이며, 양방향 마지막 상태를 연결한 48차원 벡터를 사용자 표현으로 사용한다. 알고리즘 1와 그림 1는 실제 구현의 학습 및 표현 추출 과정을 나타낸다.

3.2 행동 페르소나

학습 사용자로 표준화한 임베딩에서 $K = 2, \ldots, 8$을 탐색하고, 군집 크기, 초기화 안정성, 구매군 분리, 제거 행동과 활동 깊이를 함께 검토하여 운영값 $K = 4$를 사용하였다. 표 1와 그림 2은 군집에 속한 전체 이벤트를 분모로 한 행동 구성비를 보여준다.

P1은 조회 비율 89.93%와 중앙 행동 수 2회의 얕은 이력으로 신규 진입, 미성숙 행동, 이탈 진행 및 단일 방문이 혼합된 관측군으로 처리하였다. 고정 home persona는 P0, P2, P3으로 두고 `NEW`와 `CHURNING`을 변화 가능한 lifecycle 상태로 분리한다.

3.3 Maximum-entropy 행동과 세션 간격

세션 내 선택은 `view`, `cart`, `remove`, `purchase`, `end`의 다섯 행동이다. 상태에는 세션 위치와 경과시간, 직전 이벤트 간격, 과거 행동 횟수와 직전 행동을 사용한다. 11개 비절편 특징의 선형항, 제곱항 및 모든 2변수 교차항을 포함하여 78차원 특징 $\phi^{(2)}(s)$를 구성한다. 사용자 u의 즉시 보상과 선택확률은

$$r_u(s,a) = \theta_{u,a}^{\top} \phi^{(2)}(s), \tag{2}$$

$$\pi_u(a \mid s) = \frac{\exp r_u(s,a)}{\sum_{a'} \exp r_u(s,a')} \tag{3}$$

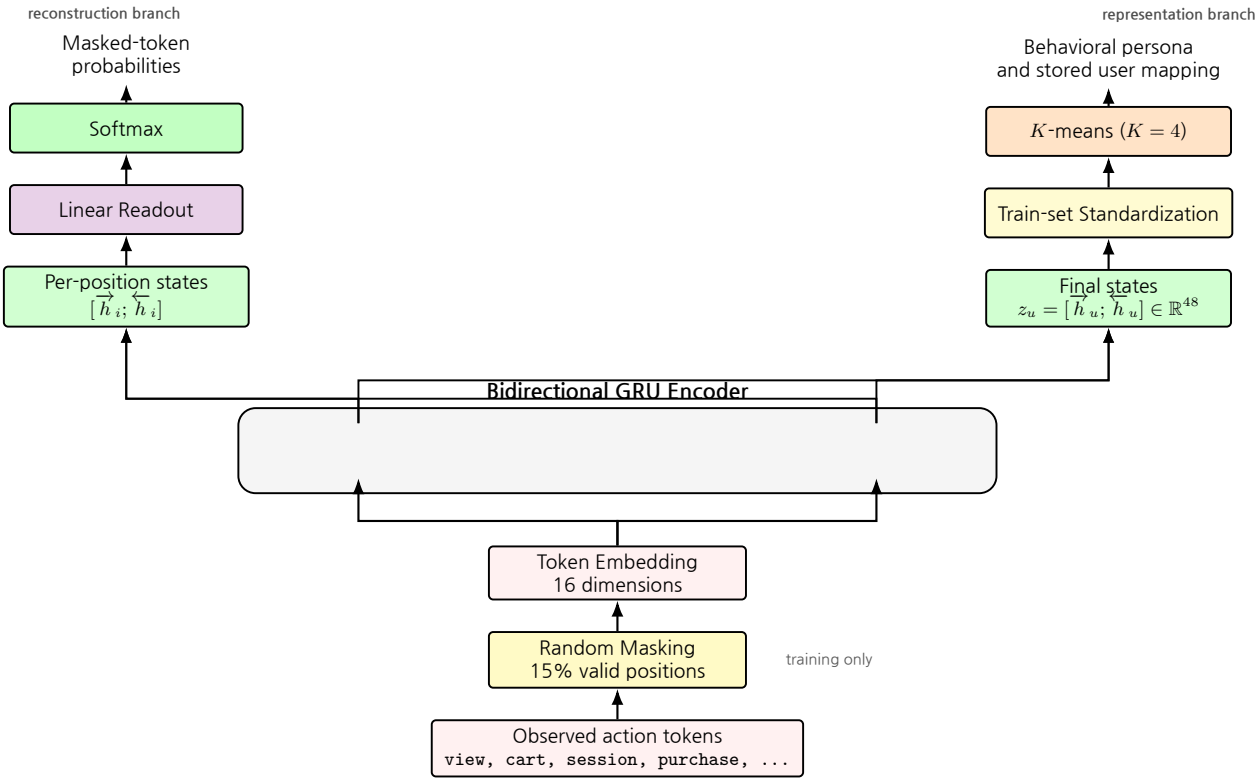


Figure 1: Masked bidirectional-GRU의 학습 및 사용자 표현 추출 구조. Transformer의 모듈식 도식 표현을 참고하되, 실제 구현에는 attention과 positional encoding이 없으며 순서 정보는 양방향 GRU가 처리한다. 왼쪽 분기는 masked-token 복원에, 오른쪽 분기는 48차원 사용자 임베딩과 행동 페르소나 구성에 사용된다.

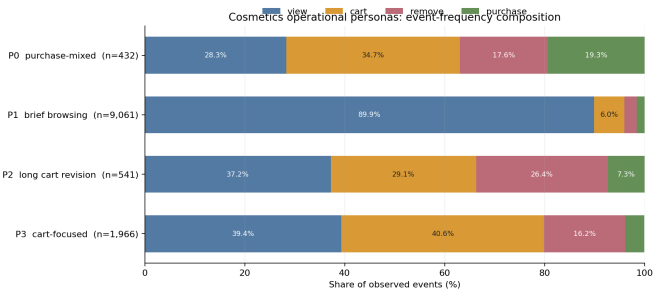


Figure 2: 운영 페르소나별 관측 이벤트 구성비. P0는 구매, P1은 조회, P2는 장기 제거 행동, P3는 장바구니 추가가 상대적으로 두드러진다.

이다. Temperature는 1로 고정하고 각 특징에서 다섯 행동 계수의 합을 0으로 제약한다. 대표 사용자 계수에는 3성분 대각 GMM을 적합하며, 모집단 혼합비는 P0 14.70%, P2 18.41%, P3 66.89%로 보정한다. 이는 장기 occupancy를 일치시키는 완전한 trajectory IRL이 아니라 상태조건부 maximum-entropy 선택모형이다 [5].

`end` 이후 간격은 0-1시간, 1-6시간, 6-24시간, 1-3일, 3-7일, 7-14일, 14-30일, `NO_RETURN_30D`의 여덟 토큰으로 샘플링한다. 첫 세션의 직전 간격은 학습 평균 51.33시간으로 초기화하되 결측 여부를 별도 지시자로 유지한다. 내부 상태 engagement, friction, satiation, inactivity momentum, gap acceleration, habit strength는 과거 세션으로 재귀 갱신되어 행동 효용과 복귀 간격을 조절한다.

3.4 합성 uplift 모듈

Tianchi 대리군의 대조 구매율 p_0와 수령 구매율 p_1을 주변 분포로 보존하면서 추가 상관을 주입하지 않는 최대엔트로피 결합을 사용한다.

$$\pi_{ST} = p_0 p_1, \quad \pi_P = (1-p_0)p_1, \quad \pi_{SD} = p_0(1-p_1), \quad \pi_{LC} = (1-p_0)$$

(4)

48차원 사용자 latent에 절편을 붙인 49×4 행렬과 softmax로 개인별 canonical type 확률을 생성한다. Persuadable에는 양의 쿠폰 offset, sleeping dog에는 음의 offset, 나머지 두 유형에는 0을 준다. 각 수령효과는

$$d(k) = \left[\max\left(0, 1 - \frac{\lfloor k/7 \rfloor}{5}\right)\right]^2, \qquad E_t = \sqrt{\sum_{r<t} d(t-r)}$$

(5)

로 35일 안에 단조 감소하며, 제곱근으로 반복 수령의 한계기여를 줄인다. 쿠폰이 없거나 strength가 0이면 모든 offset이 0이 되어 무쿠폰 생성기를 정확히 복원한다.

4 실험 결과

4.1 사용자 생성기와 uplift 보정

무쿠폰 상태에서 10,000명, 45,522세션을 생성한 결과, 전체 행동비율 RMSE는 0.0540, 구매 세션률은 관측 4.23% 대비 생성 3.94%, 30일 비복귀율은 관측 26.24% 대비 생성 21.91%였다. 2차 reward는 선형 reward보다 persona 평균 NLL을 0.648에서 0.600으로 낮췄다. Lifecycle 내부 상태를 추가하면 P0, P2, P3 평균 NLL은 0.840에서 0.808로 감소했다.

별도 6,000명으로 쿠폰 strength를 보정하고 독립 10,000명으로 검증하였다. 모집단 가중 14일 구매율 차이는 Tianchi 대리 목표 12.62%p, 생성 12.55%p로 절대오차 0.07%p였다. 이 값은 합성환경의 moment matching 결과이며 Tianchi의 인과효과 검증값이 아니다.

알고리즘 1: Masked bidirectional-GRU 사용자 임베딩 추출

입력: 시간순 이벤트 D, 최대 사용자 $U = 12000$, 길이 $L = 64$, masking $q = 0.15$
출력: 표준화된 사용자 임베딩 $\{(u, z_u)\}$, $z_u \in \mathbb{R}^{48}$

D를 사용자와 이벤트 시각으로 정렬한다;
사용자를 세션 수 1, 2, 3 이상으로 층화하여 최대 U 명을 표본화한다;
foreach 사용자 u **do**
  행동을 시간순으로 추가하고 세션 변경과 끝에 `SESSION`을 삽입한다;
  앞 L개 토큰을 유지하고 나머지 위치를 padding 한다;
사용자를 80:20 학습 및 보류 집합으로 분리한다;
for $e \leftarrow 1$ **to** 8 **do**
  유효 위치의 q를 `MASK`로 치환하되 각 시퀀스에서 하나 이상 선택한다;
  선택 위치의 원래 토큰에 대한 cross-entropy로 양방향 GRU를 갱신한다;
마스킹하지 않은 시퀀스에서 $z_u = [\overrightarrow{h}_u; \overleftarrow{h}_u]$를 추출한다;
학습 집합의 평균과 표준편차로 z_u를 표준화하고 user ID와 함께 저장한다;

Table 1: Cosmetics K=4 행동 페르소나와 이벤트 구성비 (%)

Persona	n	View	Cart	Remove	Buy	Med.
P0 구매 혼합	432	28.34	34.72	17.62	**19.32**	22
P1 짧은 조회	9,061	**89.93**	6.05	2.46	1.57	2
P2 장기 수정	541	37.21	29.11	**26.35**	7.33	**118**
P3 장바구니	1,966	39.35	**40.56**	16.24	3.84	7

4.2 주간 쿠폰 정책 비교

정책은 사용자별 주 1회 쿠폰 발송 여부를 결정하고 이후 7일의 구매, 세션과 쿠폰비를 합산하여 직전 선택의 feedback으로 받는다. 관측 상태는 persona와 lifecycle, 최근 7일 및 30일 행동, 마지막 세션과 구매 이후 경과일, 쿠폰 노출과 발송 가능 여부의 19개 과거정보 특징이다. 목적함수는

$$R = 1000 N_{\text{purchase}} - 100 N_{\text{coupon}} \tag{6}$$

이다. UCB, TS, LinUCB, LinTS, PPO [12], discrete SAC [13]를 1,000명, 13주 동안 학습하고 별도 5,000명, 52주에서 고정 정책을 평가하였다.

SAC는 매주 발송보다 순이익이 11.56% 높고 쿠폰은 59.81% 적게 사용하였다. PPO는 최종적으로 매주 발송과 같은 정책을 선택했으며 학습기간 oracle 대비 비용이 2,264,500으로 가장 컸다. 본 환경은 약 13,000개의 주간 transition만 제공하므로 on-policy PPO보다 replay를 사용하는 SAC에 표본효율 측면에서 유리할 수 있다.

5 논의 및 결론

본 연구는 행동 시퀀스, 순차적 쿠폰 반응과 정책평가를 각 요소의 식별 수준을 보존하며 연결한다. Cosmetics는 행동 생성의 근거를 제공하고, Tianchi는 비무작위 관측 차이를 합성 개입 시나리오의 모멘트로만 제공한다. 이 구조는 0효과, 감쇠율과 canonical 결합을 바꾼 민감도 실험을 가능하게 한다.

한계도 명확하다. 페르소나는 관측 행동의 기술적 군집이며 심리적 성향이나 미래 구매력의 원인이 아니다. 30일 미복귀는 영구 이탈을 보장하지 않는다. Tianchi의 수령은 무작위 처치가 아니므로 canonical 분포와 coupon offset은 인과 추정치가 아니다. 정책 결과는 전역 seed 42의 단일 실행이고 구매가치 1,000과 쿠폰비용 100은 실험용 효용 단위다. 또한 현재 정책 벤치마크는 일별 session 및 purchase를 집계한 축약환경으로, 세션 내부의 모든 행동을 매번 rollout하는 완전 통합환경은 후속 과제다.

Table 2: 주간 쿠폰 정책의 1년 고정 정책 평가

Policy	Profit/user	Purchases	Coupons
UCB	27,692.00	32.892	52.000
TS	27,692.00	32.892	52.000
LinUCB	28,959.04	30.760	18.006
LinTS	29,398.14	31.361	19.633
PPO	27,692.00	32.892	52.000
Discrete SAC	**30,893.46**	**32.984**	**20.901**
Never coupon	3,353.40	3.353	0.000
Weekly coupon	27,692.00	32.892	52.000

향후에는 다중 seed, 비용비율과 uplift 감쇠의 민감도 분석, 무작위 처치자료를 이용한 외부 검증을 수행한다. 이 검증을 통해 합성환경의 특정 가정에 종속된 정책 순위를 식별하고 실제 서비스 이전의 안전한 정책 screening 도구로 발전시킬 수 있다.

참고문헌

[1] REES46, "Free datasets with eCommerce behavior data," `https://rees46.com/en/datasets`.

[2] Alibaba Cloud Tianchi, "O2O Coupon Usage Prediction Dataset," `https://tianchi.aliyun.com/dataset/5903`.

[3] F. Sun et al., "BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer," CIKM, 2019.

[4] K. Cho et al., "Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation," EMNLP, 2014.

[5] B. D. Ziebart et al., "Maximum Entropy Inverse Reinforcement Learning," AAAI, 2008.

[6] F. Devriendt, D. Moldovan, and W. Verbeke, "A Literature Survey and Experimental Evaluation of the State-of-the-Art in Uplift Modeling," Big Data, 6(1), 2018.

[7] E. Ie et al., "RecSim: A Configurable Simulation Platform for Recommender Systems," arXiv:1909.04847, 2019.

[8] D. Rohde et al., "RecoGym: A Reinforcement Learning Environment for Product Recommendation in Online Advertising," arXiv:1808.00720, 2018.

[9] J.-C. Shi et al., "Virtual-Taobao: Virtualizing Real-World Online Retail Environment for Reinforcement Learning," AAAI, 2019.

[10] L. Li et al., "A Contextual-Bandit Approach to Personalized News Article Recommendation," WWW, 2010.

[11] S. Agrawal and N. Goyal, "Thompson Sampling for Contextual Bandits with Linear Payoffs," ICML, 2013.

[12] J. Schulman et al., "Proximal Policy Optimization Algorithms," arXiv:1707.06347, 2017.

[13] T. Haarnoja et al., "Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor," ICML, 2018.

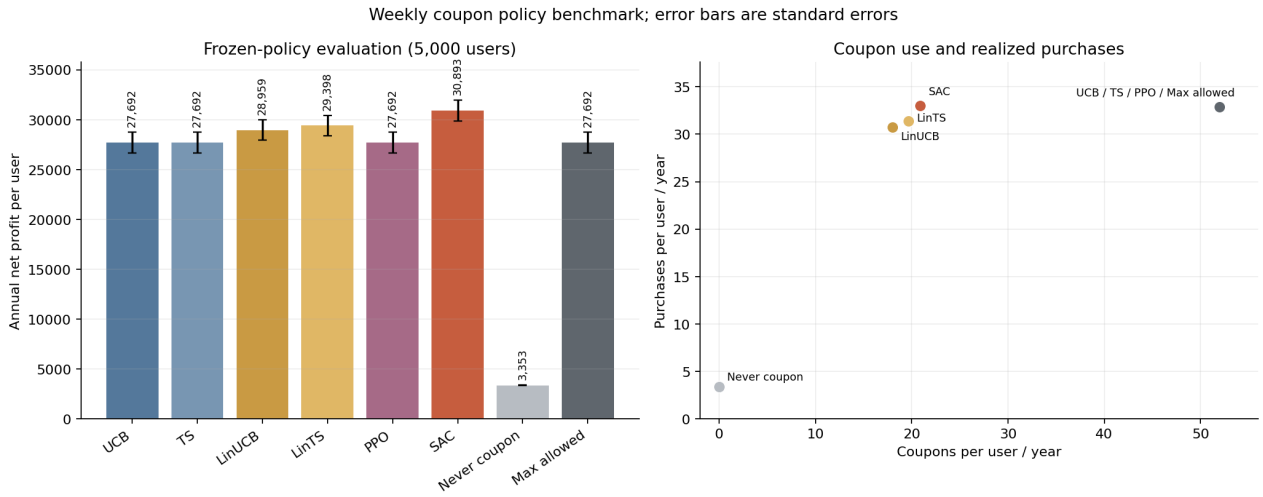


Figure 3: 5,000명, 1년 고정 정책 평가. 왼쪽 오차막대는 사용자 평균 순이익의 표준오차이며, 오른쪽은 연간 쿠폰 사용량과 구매 수의 관계다.