관측 행동 페르소나와 가정 기반 Uplift를 결합한 전자상거래 쿠폰 정책 시뮬레이터

An E-Commerce Coupon Policy Simulator Combining Observed Behavioral Personas with Assumption-Based Uplift

요 약

전자상거래의 쿠폰 정책은 즉시 구매뿐 아니라 재방문, 반복 노출 및 이탈 상태를 변화시키므로 단일 시점 구매예측만으로 평가하기 어렵다. 실제 서비스의 장기 온라인 탐색은 쿠폰비용과 사용자 피로를 유발하며, 공개 로그에서는 동일 사용자의 처치 및 비처치 잠재결과를 동시에 관측할 수 없다. 이에 본 연구는 관측 행동과 비식별 개입가정을 분리한 인과추론을 사용한 고객 시뮬레이터를 제안한다. REES46 Cosmetics Shop 로그에서 masked bidirectional-GRU로 48차원 사용자 표현을 학습하고, 행동 빈도와 세션 내 전이를 이용해 페르소나와 lifecycle을 구성하였다. 주 1회 쿠폰 환경에서 1,000명, 13주 학습 후 별도 5,000명, 52주를 평가한 결과 discrete SAC는 사용자당 20.90회의 쿠폰으로 순이익 30,893.46을 기록하였다.

주제어: 사용자 시뮬레이션, 행동 페르소나, Maximum Entropy IRL, Uplift Modeling, Contextual Bandit, 강화학습

1. 서론

쿠폰 정책은 사용자의 구매뿐 아니라 재방문과 이탈에도 영향을 미친다. 그러나 실제 사용자를 대상으로 여러 정책을 장기간 실험하려면 많은 비용이 들고, 반복적인 쿠폰 제공은 사용자 피로를 높일 수 있다. 기존 행동 로그를 활용하는 데에도 한계가 있다. 쿠폰이 무작위로 지급되지 않았다면 선택 편향이 발생할 수 있으며, 동일한 사용자가 다른 처치를 받았을 때의 결과는 관측할 수 없기 때문이다.

본 연구는 관측 데이터에서 학습한 사용자 행동과 가정에 기반한 쿠폰 개입 효과를 분리한 시뮬레이터를 제안한다. 이를 통해 실제 사용자 대상 실험의 부담을 줄이면서 다양한 쿠폰 정책을 비교하고자 한다.

행동 토큰 복원을 학습한 양방향 GRU로 사용자 표현을 구성하고, persona 조건부 최대 엔트로피 선택모형과 세션 간격 모형으로 쿠폰을 제공하지 않은 상태의 사용자 행동을 생성한다. 이를 바탕으로 구성한 합성환경에서 bandit과 deep RL의 학습 비용 및 장기 순이익을 비교한다.

순차 추천 [3]은 행동 예측에, uplift modeling [6]은 단일 결과에 대한 처치의 증분 효과 추정에 초점을 둔다. 본 연구는 공개 데이터로부터 학습한 행동 생성 과정과 별도로 설정한 쿠폰 반응을 분리한다는 점에서 RecSim [7], RecoGym [8], Virtual-Taobao [9]와 구별된다. 쿠폰 모듈을 제거하면 시뮬레이터는 쿠폰을 제공하지 않는 상태의 행동 생성기로 동작한다.

2. 데이터

사용자 행동을 학습하기 위해 REES46 Cosmetics Shop의 2019년 10월부터 2020년 2월까지의 로그를 사용하였다 [1]. 사용자 ID를 기준으로 약 1%를 고정 표본으로 추출하고, 최대 12,000명의 사용자 시퀀스를 구성하였다. 이 데이터는 상품 조회(view), 장바구니 추가(cart), 장바구니 제거(remove_from_cart), 구매(purchase) 이벤트와 세션 ID를 제공한다. Electronics 데이터는 장바구니 제거 이벤트를 포함하지 않아 보조 분석에만 활용하였다.

쿠폰 반응을 참고하기 위해 Tianchi O2O 로그를 사용하였다 [2]. 2016년 5월 15일을 기준으로 쿠폰 수령 여부에 따른 이후 14일간의 구매를 비교하였다. 대리군은 기준일 이전 14일간의 클릭과 구매 이력만으로 정의하였다. 다만 다섯 기준일에 대한 placebo 분석에서도 구매율 차이가 6.85–8.87%p로 나타났으며, 쿠폰 수령군은 이후에도 쿠폰을 받을 확률이 12.11–31.31%p 높았다. 이는 집단 간 차이에 기존 구매 성향과 후속 쿠폰 노출이 함께 반영되었을 가능성을 보여준다. 따라서 관측된 차이를 인과적 조건부 평균 처치 효과(CATE)로 해석하지 않았다.

.

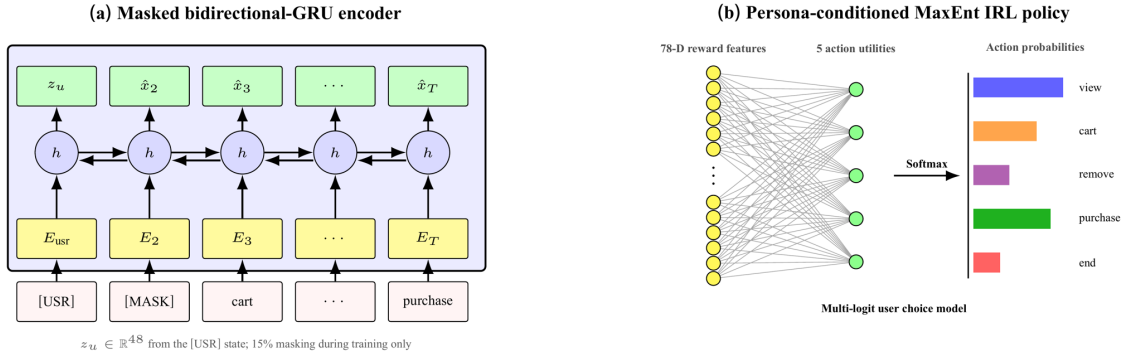


그림 1. 제안 사용자 모델의 두 학습 단계. (a) 마스킹한 행동 토큰을 복원하도록 양방향 GRU를 학습하고, 48차원 사용자 표현을 추출한다. (b) 78차원의 2차 상태 특징에 사용자–행동별 보상 계수를 적용하여 다섯 행동의 효용을 선형으로 계산한다. 이후 softmax로 변환한 행동 확률을 막대로 표시한다. 상태 특징은 세션 내 위치, 경과 시간, 직전 이벤트와의 시간 간격, 과거 행동 횟수, 직전 행동으로 구성하며, 각 특징의 제곱항과 두 특징 간 교차항을 포함한다.

3. 제안 방법

3.1 Masked bidirectional-GRU 표현

사용자 표현은 BERT4Rec의 마스킹 기반 학습 방식[3]을 참고하여 학습한다. 사용자별 행동 시퀀스에 세션 경계 토큰을 삽입하고 앞 64개 토큰을 사용하며, 유효 위치의 15%를 무작위로 마스킹한 뒤 원래 토큰을 복원하도록 양방향 GRU를 학습한다. 토큰 임베딩은 16차원이며, GRU의 은닉 상태는 방향별 24차원으로 설정한다. 학습 후에는 마스킹하지 않은 시퀀스를 입력하고, 양방향의 마지막 은닉 상태를 연결한 48차원 벡터를 사용자 표현으로 사용한다.

3.2 행동 페르소나

마스킹 GRU에서 얻은 48차원 사용자 임베딩에 $K = 4$ K-means를 적용하여 P0–P3 집단을 구성하였다. 각 집단의 전체 관측 이벤트를 분모로 한 상대 이벤트 빈도는 그림 2에 제시한다.

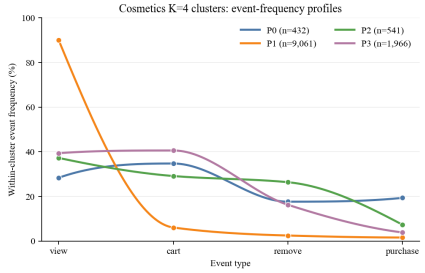


그림 2 $K = 4$ 사용자 임베딩 군집 P0–P3의 군집 내 이벤트 빈도(%). 점은 관측값이고 곡선은 네 행동 범주 사이를 PCHIP으로 연결한 시각적 보간이다.

3.3 Maximum-entropy 행동과 세션 간격

Algorithm 2: Persona-conditioned maximum-entropy IRL

Input: D, $\{c_u\}$
Output: $q(\theta)$, $q(\tau \mid s_{\text{end}})$
$X \leftarrow \phi^{(2)}(D)$
for each persona c **do**
  $\theta_c \leftarrow \arg\min_\theta \mathcal{L}_{\text{MaxEnt}}(X_c, \theta)$
  $\theta_u \leftarrow \text{MAP}(D_u \mid \theta_c)$
end for
$q(\theta) \leftarrow \text{GMM}(\{\theta_u\})$
$q(\tau \mid s_{\text{end}}) \leftarrow \text{MaxEntGap}(D)$

세션 내 선택은 `view`, `cart`, `remove`, `purchase`, `end`의 다섯 행동이다. 상태에는 세션 위치와 경과시간, 직전 이벤트 간격, 과거 행동 횟수와 직전 행동을 사용한다. 11개 비절편 특징의 선형항, 제곱항 및 모든 2변수 교차항을 포함하여 78차원 특징 $\phi^{(2)}(s)$를 구성한다. 사용자 u의 즉시 보상과 선택확률은

$$r_u(s,a) = \theta_{u,a}^{\top} \phi^{(2)}(s), \tag{2}$$

$$\pi_u(a \mid s) = \frac{\exp r_u(s,a)}{\sum_{a'} \exp r_u(s,a')} \tag{3}$$

이다. Temperature는 1로 고정하고 각 특징에서 다섯 행동 계수
의 합을 0으로 제약한다. 대표 사용자 계수에는 3성분 대각 GMM을 적합하며, 모집단 혼합비는 P0 14.70%, P2 18.41%, P3 66.89%로 보정한다. 이는 장기 occupancy를 일치시키는 완전한 trajectory IRL이 아니라 상태조건부 maximum-entropy 선택 모형이다 [5].

`end` 이후 간격은 0–1시간, 1–6시간, 6–24시간, 1–3일, 3–7일, 7–14일, 14–30일, `NO_RETURN_30D`의 여덟 토큰으로 샘플링한다. 첫 세션의 직전 간격은 학습 평균 51.33시간으로 초기화하되 결측 여부를 별도 지시자로 유지한다. NEW, home persona, CHURNING 및 두 종료상태의 전이는 그림 4과 같다.

3.4 합성 uplift 모듈

Algorithm 3: Sequential uplift calibration

Input: G, Z, $\{\pi_c^{\text{can}}, \Delta_c^*\}_{c \in \mathcal{C}}$
Output: W^*, λ^*
$G \leftarrow \text{freeze}(G)$
$W^* \leftarrow \text{FitCanonical}(Z, \pi^{\text{can}})$
for each $k = 0, \ldots, K-1$ **do**
  $\hat{\Delta}^{(k)} \leftarrow \text{PairedRollout}(G, W^*, \lambda^{(k)}, \omega_k)$
  $\lambda_c^{(k+1)} \leftarrow \lambda_c^{(k)} \Delta_c^* / \hat{\Delta}_c^{(k)}$
end for
$\lambda^* \leftarrow \lambda^{\left(\arg\min_k \|\hat{\Delta}^{(k)} - \Delta^*\|_2\right)}$

Tianchi에는 장바구니와 세션 경계가 없으므로 처치 이전의 공통 행동공간만 사용한다. 사용자 i의 행동요약과 대리군, Cosmetics persona 대응은

$$h_i^- = \left(n_{i,\text{click}}^-, n_{i,\text{purchase}}^-, n_{i,\text{active}}^-\right), \qquad g_i = \Gamma\left(h_i^-; q_{.25}, q_{.75}, q_{.95}\right),$$
$$m(0) = g_{\text{purchase}}, \qquad m(2) = g_{\text{deep}}, \qquad m(3) = g_{\text{browse}} \tag{4}$$

로 정의한다. 여기서 Γ는 처치 이전 활동량과 구매 유무의 분위수 규칙이며, m은 공통된 탐색 깊이와 구매 이력을 이용한 persona–proxy 대응이다. $H = 14$, $A_i \in \{0,1\}$ 및 $Y_i^{(H)} = \mathbb{1}\left[\sum_{d=1}^{H} N_{i,d}^{\text{purchase}} > 0\right]$에 대해

$$p_{c,a} = \mathbb{E}\left[Y_i^{(H)} \mid g_i = m(c), A_i = a\right], \qquad \Delta_c^* = p_{c,1} - p_{c,0} \tag{5}$$

를 보정 모멘트로 둔다. 주변분포를 보존하면서 추가 상관을 주입하지 않는 최대엔트로피 결합을 위해

$$\mathcal{T} = \{ST: (1,1),\ P: (0,1),\ SD: (1,0),\ LC: (0,0)\} \tag{6}$$

의 네 canonical type을 정의한다. 각 순서쌍은 $\left(Y^{(H)}(0), Y^{(H)}(1)\right)$이며, 각 persona의 목표분포는

$$\pi_{c,ST} = p_{c,0} p_{c,1}, \qquad \pi_{c,P} = \left(1 - p_{c,0}\right) p_{c,1},$$
$$\pi_{c,SD} = p_{c,0}\left(1 - p_{c,1}\right), \qquad \pi_{c,LC} = \left(1 - p_{c,0}\right)\left(1 - p_{c,1}\right) \tag{7}$$

48차원 사용자 latent에 절편을 붙인 49×4 행렬과 softmax로 개인별 canonical type 확률을 생성하고 persona별 평균이 목표분포를 근사하도록 학습한다. 그림 3(a)는 persona별 목표분포를 나타낸다. Persuadable에는 양의 쿠폰 offset, sleeping dog에는 음의 offset, 나머지 두 유형에는 0을 준다. 각 수령효과는

$$d(k) = \left[\max\left(0, 1 - \frac{\lfloor k/7 \rfloor}{5}\right)\right]^2, \qquad E_t = \sqrt{\sum_{r<t} d\,(t-r)} \tag{8}$$

로 35일 안에 단조 감소하며, 제곱근으로 반복 수령의 한계기여를 줄인다. 쿠폰이 없거나 strength가 0이면 모든 offset이 0이 되어 무쿠폰 생성기를 정확히 복원한다.

본 단계는 행동 생성기를 계속 갱신하는 continual learning이 아니다. Cosmetics에서 학습한 reward, coefficient GMM 및 세션 간격 모형을 동결한 뒤, Tianchi 모멘트를 이용해 canonical-type 매핑과 persona별 쿠폰 강도만 순차적으로 보정한다. 따라서 무쿠폰 행동 적합도를 보존하면서 uplift 가정만 별도로 교체하거나 검증할 수 있다.

표 1 주간 쿠폰 정책의 1년 고정 정책 평가: 평균(표준편차)

Policy	Profit/user ($\times 10^3$)	Purch./user	Coupons/user
UCB	27.69 (75.21)	32.89 (75.21)	52.00 (0.00)
TS	27.69 (75.21)	32.89 (75.21)	52.00 (0.00)
LinUCB	28.96 (73.15)	30.76 (74.35)	18.01 (18.76)
LinTS	29.40 (73.34)	31.36 (74.51)	19.63 (19.20)
PPO	27.69 (75.21)	32.89 (75.21)	52.00 (0.00)
Discrete SAC	**30.89 (73.83)**	**32.98 (75.07)**	**20.90 (17.00)**
Never coupon	3.35 (2.48)	3.35 (2.48)	0.00 (0.00)
Weekly coupon	27.69 (75.21)	32.89 (75.21)	52.00 (0.00)

4. 실험 결과

4.1 사용자 생성기와 쿠폰 반응 보정

쿠폰을 제공하지 않는 조건에서 가상 사용자 10,000명의 행동을 생성하고, 실제 로그에서 집계한 행동 통계와 비교하였다. 여기서 관측값은 실제 사용자의 행동 로그에서 계산한 값이며, 생성값은 학습한 사용자 모델이 시뮬레이션에서 만들어 낸 행동으로부터 계산한 값이다.

행동 비율의 RMSE는 0.0540이었다. 구매가 발생한 세션의 비율은 관측값 4.23%, 생성값 3.94%였으며, 30일 이내 재방문 비율은 각각 26.24%와 21.91%였다. 생성된 행동은 전반적인 행동 비율을 반영했으나, 재방문 비율은 실제 로그보다 낮게 나타났다.

2차 보상함수를 적용한 뒤 persona 분류의 평균 음의 로그우도(NLL)는 0.648에서 0.600으로, lifecycle 상태 분류의 평균 NLL은 0.840에서 0.808로 감소하였다. 쿠폰 반응은 별도의 가상 사용자 6,000명으로 보정하고 10,000명으로 확인하였다. 이때 목표 구매확률 증가분과 보정 결과의 차이는 0.07%p였다. 그림 3은 persona별 canonical type 분포와 보정된 home-persona 혼합비로 생성한 사용자 표현을 보여준다.

.

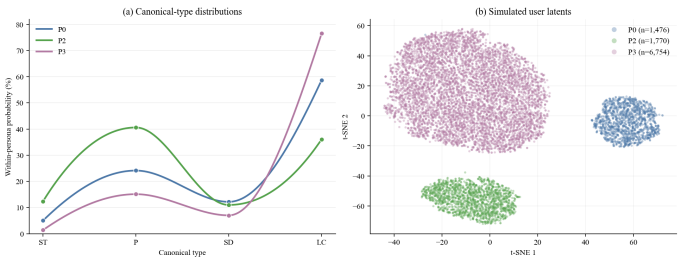


그림 3. 합성 사용자의 유형 분포와 사용자 표현. (a) persona별 canonical type 분포. ST, P, SD, LC는 각각 sure thing, persuadable, sleeping dog, lost cause를 뜻한다. (b) 합성 사용자 10,000명의 48차원 표현을 t-SNE로 시각화한 결과. t-SNE 좌표는 시각화에만 사용하며 행동 생성에는 사용하지 않는다.

4.2 주간 쿠폰 정책 비교

정책은 사용자별로 매주 한 번 쿠폰 발송 여부를 결정한다. 각 결정의 보상은 이후 7일간의 구매 건수와 쿠폰 비용을 반영하여 다음과 같이 계산하였다.

$$R = 1000N_{\text{purchase}} - 100N_{\text{coupon}} \tag{9}$$

UCB, TS, LinUCB, LinTS, PPO [12], discrete SAC [13]를 1,000명, 13주 동안 학습하고 별도 5,000명, 52주에서 고정 정책을 평가하였다.

SAC는 매주 쿠폰을 발송하는 정책보다 순이익이 11.56% 높았으며, 쿠폰 비용은 59.81% 적었다. PPO는 최종적으로 매주 쿠폰을 발송하는 정책과 같은 선택을 했지만, 해당 정책을 직접 적용하는 oracle 기준과 비교하면 학습 기간에 2,264,500의 누적 순이익 손실이 발생하였다. 본 환경은 약 13,000개의 주간 전이만 제공하므로, 경험을 재사용하는 SAC가 on-policy 방식의 PPO보다 표본을 효율적으로 활용했을 가능성이 있다.

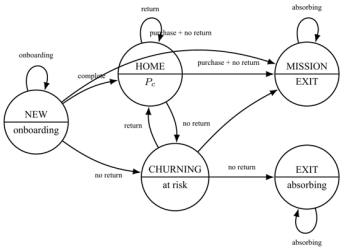


그림 4. 세션 종료 시 적용되는 lifecycle 상태 전이. P_c는 사용자 생성 시 고정한 home persona를 나타낸다. MISSION EXIT와 EXIT는 30일 동안 재방문하지 않는 상태를 나타내며, 한 번 진입하면 다른 상태로 이동하지 않는다.

5. 논의 및 결론

본 연구는 Cosmetics 로그에서 학습한 사용자 행동 생성기와 Tianchi를 참고해 설정한 합성 쿠폰 반응 모듈을 결합하여 순차 쿠폰 정책을 평가하였다. 실제 로그는 사용자의 기본 행동을 학습하는 데 사용하고, 쿠폰에 따른 행동 변화는 별도의 가정과 보정 과정을 통해 설정하였다. 두 요소를 분리함으로써 기본 행동 모형을 유지한 채 쿠폰 효과, 감쇠율, 사용자 유형의 혼합비를 바꾸어 정책 성과를 비교할 수 있도록 하였다.

실험에서는 SAC가 매주 쿠폰을 발송하는 정책보다 적은 비용으로 높은 순이익을 얻었다. 다만 이 결과는 본 연구에서 설정한 사용자 구성과 쿠폰 반응, 학습 예산 아래에서 얻은 결과이다. persona는 행동을 요약하기 위한 기술적 군집이며, Tianchi의 쿠폰 수령 여부도 무작위로 결정되지 않았다. 따라서 canonical type의 분포와 쿠폰 효과 보정값을 실제 사용자의 인과적 반응으로 해석하기는 어렵다.

실무에서는 이 시뮬레이터를 실제 서비스에 적용할 정책 후보를 좁히는 사전 실험 도구로 활용할 수 있다. 쿠폰 예산이나 효과의 지속 기간을 달리했을 때에도 성과를 유지하는 정책을 찾고, 학습 과정에서 발생하는 비용을 비교하는 데 유용하다. 후속 연구에서는 사용자별 쿠폰 반응의 불확실성과 반복 노출에 따른 피로를 모형에 반영하고, 서비스 실험에서 축적한 결과로 쿠폰 반응 모듈을 갱신하는 방향으로 발전시키고자 한다.

.

참고문헌

[1] REES46, “Free datasets with eCommerce behavior data,” https://rees46.com/en/datasets.

[2] Alibaba Cloud Tianchi, “O2O Coupon Usage Prediction Dataset,”

https://tianchi.aliyun.com/dataset/5903.

[3] F. Sun et al., “BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer,” *CIKM*, 2019.

[4] K. Cho et al., “Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation,” *EMNLP*, 2014.

[5] B. D. Ziebart et al., “Maximum Entropy Inverse Reinforcement Learning,” *AAAI*, 2008.

[6] F. Devriendt, D. Moldovan, and W. Verbeke, “A Literature Survey and Experimental Evaluation of the State-of-the-Art in Uplift Modeling,” *Big Data*, 6(1), 2018.

[7] E. Ie et al., “RecSim: A Configurable Simulation Platform for Recommender Systems,” arXiv:1909.04847, 2019.

[8] D. Rohde et al., “RecoGym: A Reinforcement Learning Environment for Product Recommendation in Online Advertising,” arXiv:1808.00720, 2018.

[9] J.-C. Shi et al., “Virtual-Taobao: Virtualizing Real-World Online Retail Environment for Reinforcement Learning,” *AAAI*, 2019.

[10] L. Li et al., “A Contextual-Bandit Approach to Personalized News Article Recommendation,” *WWW*, 2010.

[11] S. Agrawal and N. Goyal, “Thompson Sampling for Contextual Bandits with Linear Payoffs,” *ICML*, 2013.

[12] J. Schulman et al., “Proximal Policy Optimization Algorithms,” arXiv:1707.06347, 2017.

[13] T. Haarnoja et al., “Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor,” *ICML*, 2018.